

BOOTCAMP DATA ANALYTICS

Enero 2026

PROYECTO INTEGRADOR FINAL

Análisis y Construcción de Cartera de Inversión S&P 500

Autor: Jesús Cuenca

Fecha: 29 Junio 2026

1. Resumen Ejecutivo

El presente proyecto analiza el universo de empresas cotizadas en el índice S&P 500 con el objetivo de construir una cartera de inversión diversificada de 50.000 €, adecuada para un perfil inversor moderado.

A partir de dos datasets de Kaggle (más de 200 indicadores financieros por empresa y listado oficial del S&P 500), se aplicó un proceso completo de Data Analytics: limpieza de datos en Python sobre un universo inicial de 3.808 empresas, filtrado por KPIs en SQL que redujo el universo a 242 empresas candidatas, análisis exploratorio (EDA), y técnicas de Machine Learning (PCA, K-Means y Regresión Lineal).

El Cluster 2 fue identificado como el perfil ganador (margen neto 37%, crecimiento 94%, deuda moderada). La cartera final está compuesta por 20 empresas seleccionadas de 4 sectores (Technology, Healthcare, Energy y Basic Materials), con una distribución de capital proporcional a un score ponderado de KPIs financieros. Los KPIs agregados de la cartera son: ROE medio ponderado 27,49%, margen neto medio 37,34% y deuda media 25,64%.

2. Introducción

Contexto y motivación

La selección de activos financieros mediante análisis de datos sistemático permite superar la intuición y los sesgos cognitivos habituales en la toma de decisiones de inversión. Este proyecto aplica las herramientas y metodologías aprendidas durante el bootcamp a un caso práctico y realista: la construcción de una cartera de inversión en renta variable americana.

Objetivos generales

- Demostrar el ciclo analítico completo: desde datos brutos hasta una decisión de inversión justificada.
- Aplicar técnicas de limpieza, SQL, EDA y Machine Learning de forma integrada.
- Construir una cartera diversificada de 50.000 € con criterio cuantitativo y transparente.

Objetivos específicos

- Identificar los sectores del S&P 500 con mejor combinación de rentabilidad y riesgo.

- Seleccionar empresas que superen umbrales de calidad financiera definidos por KPIs.
- Aplicar K-Means para identificar perfiles naturales de empresas.
- Distribuir el capital de forma proporcional al score financiero de cada empresa.

3. Descripción de los Datos

Fuente de datos

Ambos datasets proceden de Kaggle:

- 200+ Financial Indicators of US Stocks (2014-2018): dataset principal con más de 200 indicadores financieros por empresa cotizada en el S&P 500.
- S&P 500 Companies: listado oficial de empresas del índice con clasificación sectorial GICS.

Volumen y variables principales

El dataset original cuenta con 3.808 empresas. Tras el proceso de limpieza y filtrado, el universo de análisis quedó en 1.124 empresas distribuidas entre los 4 sectores objetivo. Las variables principales utilizadas son:

KPI	Descripción	Uso en el proyecto
ROE	Return on Equity	Rentabilidad sobre recursos propios
Net Profit Margin	Margen neto	Eficiencia en conversión de ventas a beneficio
Debt to Equity	Deuda sobre patrimonio	Nivel de apalancamiento financiero
PE Ratio	Precio / Beneficio	Valoración de mercado
Revenue Growth	Crecimiento de ingresos	Dinamismo y potencial de expansión

Limitaciones

- Los datos corresponden al período 2014-2018, por lo que no reflejan el comportamiento reciente del mercado.

- No se dispone de datos de volatilidad histórica ni Sharpe Ratio calculados, por lo que los KPIs de calidad de cartera son aproximaciones basadas en indicadores fundamentales.
- La columna Class (etiqueta supervisada de ganadora/perdedora) fue utilizada para validación pero no como variable objetivo principal.

4. Preparación y Limpieza de Datos

Proceso de filtrado

La limpieza se realizó en Python (Google Colab) en tres etapas sucesivas:

Paso	Empresas restantes	Criterio aplicado
Dataset original	3.808	-
Filtrado por 4 sectores objetivo	1.621	Technology, Healthcare, Energy, Basic Materials
Eliminación de nulos en KPIs	1.535	Se eliminaron filas con algún KPI vacío
Eliminación de outliers extremos	1.124	Rangos financieros lógicos por KPI

Tratamiento de outliers

Se definieron rangos aceptables con criterio financiero, no estadístico, para evitar eliminar empresas válidas:

KPI	Rango aceptable	Justificación
ROE	Entre -1 y 1	Entre -100% y 100%
Net Profit Margin	Entre -1 y 1	Entre -100% y 100%
Debt to Equity	Entre 0 y 10	Endeudamiento razonable
PE Ratio	Entre 0 y 100	PER realista para empresas cotizadas
Revenue Growth	Entre -1 y 5	Crecimiento del -100% al +500%

Tras la limpieza, las medianas de los KPIs son completamente realistas: ROE 6,7%, margen neto 3,5%, deuda/equity 0,24, PE ratio 13,5 y crecimiento 6%. El dataset limpio quedó listo para el análisis.

5. Base de Datos SQL

Sistema gestor utilizado

Para el almacenamiento y consulta de los datos se utilizó SQLite gestionado a través de DBeaver. Esta decisión responde a la naturaleza del proyecto: al tratarse de un análisis local sobre un dataset estático, SQLite ofrece todas las capacidades relacionales necesarias sin requerir la configuración de un servidor externo. El archivo cartera_sp500.db queda integrado directamente en el repositorio del proyecto, facilitando su portabilidad y reproducibilidad.

Filtrado por KPIs por sector

Se creó la tabla empresas_sp500 con las 1.124 empresas limpias, y se aplicó filtrado sector a sector con los umbrales de calidad financiera definidos:

Sector	Universo	KPI mínimo	ROE	KPI mínimo	Margen	Empresas candidatas
Technology	460	$\geq 15\%$		$\geq 15\%$		76
Healthcare	292	$\geq 15\%$		$\geq 10\%$		53
Energy	178	$\geq 12\%$		$\geq 8\%$		72
Basic Materials	194	$\geq 10\%$		$\geq 8\%$		41
TOTAL	1.124	-		-		242

El resultado final fue la tabla empresas_candidatas con 242 empresas que superan los umbrales de calidad financiera definidos para cada sector. El script completo está disponible en sql/02_filtrado_kpis.sql del repositorio.

6. Análisis Exploratorio (EDA)

Estadísticas descriptivas

Las 242 empresas candidatas presentan el siguiente perfil medio:

KPI	Media	Mediana	Desv. Estándar	Lectura
ROE	19,19%	16,8%	0,15	Rentabilidad sólida
Net Profit Margin	17,63%	13,6%	0,13	Buena conversión ventas-beneficio

KPI	Media	Mediana	Desv. Estándar	Lectura
Debt to Equity	0,49	0,29	0,58	Apalancamiento moderado
PE Ratio	21,3	18,2	10,4	Valoración razonable
Revenue Growth	24,07%	14,5%	0,32	Alto crecimiento con dispersión

Distribuciones

- Los KPIs muestran distribuciones asimétricas hacia la derecha, típicas de datos financieros: la mayoría de empresas se concentra en valores moderados con pocos casos excepcionales.
- El Revenue Growth es el KPI más disperso (desv. est. 0,32 > media 0,24), indicando alta variabilidad en el crecimiento entre empresas candidatas.
- El Debt to Equity está muy concentrado cerca de 0, confirmando que los filtros SQL seleccionaron empresas con bajo apalancamiento.

Correlaciones entre KPIs

- ROE ↔ Net Profit Margin (0,28): empresas más rentables tienden a tener mejor margen.
- Net Profit Margin ↔ Revenue Growth (0,33): la correlación más alta, empresas con mejor margen tienden a crecer más.
- PE Ratio ↔ ROE (-0,11): empresas muy caras en bolsa no son necesariamente las más rentables internamente.
- Conclusión clave: las correlaciones son moderadas o bajas, lo que justifica el uso de los 5 KPIs en PCA y K-Means sin riesgo de multicolinealidad.

7. Dashboard

Objetivos del dashboard

El dashboard desarrollado en Power BI tiene como objetivo comunicar visualmente la composición de la cartera final y el perfil financiero de las empresas seleccionadas, facilitando la interpretación de los resultados para la toma de decisiones.

Página 1 — Visión General

- Tabla interactiva con las 20 empresas de la cartera: ticker, sector, peso (%) e inversión en €.
- Gráfico circular con la distribución de inversión por sector, mostrando la diversificación de la cartera.

Página 2 — Perfil Financiero

- Gráfico de barras horizontal con el ROE de cada empresa ordenado de mayor a menor, justificando la selección.
- Gráfico de dispersión Margen Neto vs Deuda, con el tamaño de cada burbuja proporcional a la inversión asignada. Permite visualizar el equilibrio rentabilidad/riesgo de toda la cartera de un vistazo.

KPIs utilizados

- Peso (%): participación de cada empresa en la cartera, proporcional a su score total.
- Inversión (€): capital asignado a cada empresa sobre los 50.000 € totales.
- ROE, Net Profit Margin, Debt to Equity: KPIs financieros fundamentales para evaluar el perfil de cada empresa.

8. Técnicas Analíticas Aplicadas

8.1 StandardScaler — Estandarización

Antes de aplicar PCA y K-Means, los 5 KPIs fueron estandarizados con StandardScaler (media=0, desviación estándar=1). Esto es necesario porque los KPIs tienen escalas muy distintas: el PE Ratio oscila entre 5 y 60, mientras que el ROE está entre 0 y 1. Sin estandarizar, las variables de mayor escala dominarían el análisis.

8.2 PCA — Análisis de Componentes Principales

El PCA redujo los 5 KPIs a 2 componentes principales que capturan el 55% de la varianza total (CP1: 28,41%, CP2: 26,59%). Esto permitió visualizar las 242 empresas en un espacio bidimensional, donde se observa que los 4 sectores no se separan claramente por sus KPIs —

la selección previa por umbrales garantizó que todas las empresas candidatas tienen un perfil financiero similar de base.

8.3 K-Means — Segmentación de empresas

Se aplicó K-Means con k=4 clusters, elegido mediante el método del codo y por coincidir con los 4 sectores del proyecto. Los 4 clusters identificados son:

Cluster	Empresas	ROE	Margen	Deuda	Crecimiento	Perfil
0	48	17%	16%	0,25	27%	Crecimiento con valoración alta (PER 36,6)
1	39	30%	16%	1,30	15%	Rentabilidad con deuda alta
2	20	22%	37%	0,39	94%	Estrellas de crecimiento (GANADOR)
3	135	16%	16%	0,35	15%	Perfil conservador moderado

El Cluster 2 fue seleccionado como perfil preferente para la cartera por su combinación de margen neto excepcional (37%) y crecimiento elevado (94%) con deuda moderada. Para Basic Materials, sector sin representación en el Cluster 2, se utilizaron las 5 empresas del Cluster 0 (deuda muy baja, crecimiento razonable).

8.4 Score ponderado — Asignación de pesos

Para seleccionar las 5 mejores empresas por sector y asignar pesos en la cartera, se construyó un score ponderado mediante normalización Min-Max de cada KPI y promedio ponderado:

- ROE: 30% — rentabilidad sobre recursos propios
- Net Profit Margin: 30% — eficiencia en conversión de ventas
- Debt to Equity: 25% — riesgo financiero (invertido: menor deuda = mayor score)
- Revenue Growth: 15% — potencial de crecimiento

El peso de cada empresa en la cartera es proporcional a su score total, de modo que las empresas con mejor perfil financiero reciben mayor asignación de capital.

8.5 Regresión Lineal — Validación

Se aplicó regresión lineal múltiple para predecir el ROE a partir del resto de KPIs. El modelo obtuvo $R^2=0,1138$ (explica el 11,38% de la variación del ROE) y $MAE=0,0725$ (error medio de 7,25 puntos porcentuales). Aunque el R^2 es bajo, es coherente con la naturaleza multifactorial del ROE — factores como la calidad directiva, posición competitiva o contexto macroeconómico no están recogidos en el dataset. El coeficiente más influyente fue el Net Profit Margin (+0,4211), lo que confirma que la eficiencia en la conversión de ventas es el principal driver de rentabilidad.

9. Conclusiones y Recomendaciones

Principales hallazgos

- De 3.808 empresas del S&P 500, solo 242 (6,4%) superan los umbrales de calidad financiera definidos, lo que evidencia la selectividad del análisis.
- El Cluster 2 (20 empresas) representa el perfil financiero óptimo para una cartera moderada: margen neto 37%, crecimiento 94%, deuda moderada.
- Healthcare lidera en rentabilidad ajustada al riesgo (ROE 19,7%, margen 19,5%), siendo el sector más equilibrado del universo candidato.
- La correlación más fuerte entre KPIs es Margen Neto ↔ Crecimiento de Ingresos (0,33), lo que sugiere que las empresas eficientes son también las que más crecen.
- La regresión lineal confirmó que el Net Profit Margin es el principal predictor del ROE, reforzando su peso del 30% en el score ponderado.

Cartera final

La cartera de 20 empresas (5 por sector) distribuye los 50.000 € con los siguientes KPIs agregados ponderados:

- ROE medio ponderado: 27,49%
- Margen neto medio ponderado: 37,34%
- Deuda media ponderada: 25,64%

Limitaciones del análisis

- Los datos son históricos (2014-2018) y no predicen el comportamiento futuro del mercado.
- No se han calculado métricas de cartera dinámicas como Sharpe Ratio o Beta real, al no disponer de series temporales de precios.
- La empresa REI (Energy) presenta un crecimiento de ingresos del 269%, posible outlier dentro del Cluster 2 que merece seguimiento.

Próximos pasos sugeridos

- Incorporar datos de precios históricos para calcular volatilidad real, Beta y Sharpe Ratio de la cartera.
- Aplicar backtesting para evaluar el rendimiento histórico de la cartera seleccionada.
- Actualizar el dataset con datos recientes y reevaluar el clustering y la selección de empresas.
- Considerar la inclusión de criterios ESG como capa adicional de filtrado.

10. Bibliografía y Referencias

- Dataset principal: 200+ Financial Indicators of US Stocks (2014-2018). Kaggle. <https://www.kaggle.com/>
- Dataset secundario: S&P 500 Companies. Kaggle. <https://www.kaggle.com/>
- Fernández, P. (2013). *Valoración de empresas y sensatez*. IESE Business School, Universidad de Navarra.
- Martínez Abascal, E. (2009). *Finanzas para directivos*. McGraw-Hill / IESE Publishing.
- Repositorio del proyecto: <https://github.com/jcuencar/sp500-cartera-analisis>